[NOME DA INSTITUICAO]
[NOME DO PROGRAMA]
Programa Institucional de Bolsas de Iniciacao Cientifica
(PIBIC/CNPq)

RELATORIO PARCIAL DE PESQUISA

PVM2263-2025
FLORA: Friendly Local Open Resource for Analysis

Bolsista: Joao Pedro Pereira Santiago
Orientador: Prof. Dr. Diego Lisboa Rios
Periodo de avaliacao: Agosto/2025 a Marco/2026

[Cidade – Estado]
Abril de 2026

Abstract

Este relatorio apresenta os resultados parciais do projeto FLORA (*Friendly Local Open Resource for Analysis*), uma biblioteca em Python voltada para analise ponta a ponta de dados de microbioma baseados em amplicons do gene rRNA 16S. No periodo avaliado, o projeto evoluiu de uma proposta inicialmente centrada em interface para uma arquitetura de biblioteca cientifica robusta, organizada em camadas de ingestao, armazenamento analitico, engenharia de atributos, aprendizado de maquina, visualizacao e geracao automatizada de relatorios. Como resultado, foram consolidados um nucleo analitico baseado em DuckDB e Parquet, modulos de normalizacao composicional com transformacao CLR, rotinas de calculo de diversidade alfa e beta, modelos supervisionados com *scikit-learn*/XGBoost e uma pipeline de relatorios interativos e documentacao cientifica. Em avaliacao experimental com dados do Earth Microbiome Project (EMP), a pipeline processou 89 amostras, preservou 1.183 atributos apos filtragem de prevalencia e obteve acuracia de 0,8636, F1-macro de 0,6381 e ROC-AUC de 0,9510 na classificacao de categorias ambientais. Os resultados indicam maturidade suficiente para a etapa seguinte, focada em usabilidade, ampliacao metodologica e validacao em novas bases publicas.

Palavras-chave: microbioma, rRNA 16S, bioinformatica, machine learning, DuckDB, composicionalidade.

Contents

1 Introducao **3**

2 Objetivos **3**

2.1 Objetivo Geral 3

2.2 Objetivos Especificos 4

3 Metodologia **4**

3.1 Arquitetura de Dados 4

3.2 Engenharia de Atributos 4

3.3 Modelagem e Avaliacao 4

3.4 Hipotese Experimental 5

3.5 Ligacao entre pipeline biologico e modelagem 5

3.6 Documentacao e Visualizacao 5

4 Resultados Parciais e Discussao **5**

4.1 Experimento com Earth Microbiome Project 6

4.2 Comparacao metodologica 7

4.3 Relacao entre ML e biologia 7

4.4 Interpretacao dos Graficos 7

4.5 Limitacoes 8

5 Cronograma e Proximos Passos **8**

5.1 Plano de acao imediato 8

6 Conclusao Parcial **9**

1. Introducao

A analise de comunidades microbianas independentes de cultivo se consolidou como uma das principais abordagens para investigacao de ambientes naturais, sistemas hospedeiros e processos ecologicos. No contexto de microbiomas, o sequenciamento de amplicons do gene rRNA 16S permanece como uma estrategia amplamente adotada por apresentar custo relativamente reduzido, protocolos padronizados e vasta base comparativa na literatura. Ferramentas como QIIME 2 [1] e DADA2 [2] elevaram o rigor da area ao permitir inferencia de variantes de sequencia de alta resolucao.

Apesar desse avanco, ainda persiste um gargalo importante entre o processamento primario dos dados e a construcao de modelos interpretaveis de aprendizado de maquina. Em geral, o pesquisador precisa integrar manualmente diferentes formatos de entrada, bancos de dados, bibliotecas de transformacao estatistica, pacotes de visualizacao e modelos preditivos. Esse acoplamento manual aumenta a complexidade do fluxo de trabalho, dificulta reproducibilidade e compromete a adocao por usuarios com menor familiaridade em programacao cientifica.

Outro ponto critico e a natureza composicional dos dados de abundancia microbiana. Matrizes de ASVs representam distribuicoes relativas, nao medidas absolutas independentes, de modo que abordagens estatisticas convencionais podem introduzir correlacoes espurias e interpretacoes enviesadas. A literatura recomenda transformacoes log-ratio, como CLR, para reduzir esse problema [3], mas tais procedimentos frequentemente permanecem ausentes ou opcionais em pipelines aplicados.

Nesse contexto, o projeto **FLORA** foi concebido como uma infraestrutura local, aberta e integrada para analise de microbiomas. A proposta combina armazenamento analitico embutido, transformacoes composicionais, machine learning e geracao de relatorios em uma unica base de codigo, tornando o pipeline mais reproduzivel, auditavel e acessivel.

2. Objetivos

2.1. Objetivo Geral

Desenvolver uma biblioteca e plataforma local em Python para analise ponta a ponta de dados de amplicons 16S rRNA, integrando ingestao, armazenamento analitico, transformacoes composicionais, aprendizado de maquina e geracao automatizada de relatorios.

2.2. Objetivos Especificos

- desenvolver uma interface de uso amigavel, em CLI e camada web local, sobre um nucleo cientifico reutilizavel;
- implementar uma arquitetura de armazenamento analitico local capaz de operar com dados maiores que a memoria RAM;
- incorporar tecnicas adequadas para dados composicionais, especialmente a transformacao CLR, como etapa padrao para modelagem;
- integrar processamento de sequencias e estruturas de dados oriundas de QIIME 2/DADA2;
- disponibilizar modulos de visualizacao, relatorios e interpretabilidade de modelos.

3. Metodologia

O desenvolvimento foi estruturado em modulos independentes, seguindo principios de engenharia de software cientifico e validacao incremental.

3.1. Arquitetura de Dados

Foi adotado o **DuckDB** [4] como motor analitico local. A escolha se deve ao suporte eficiente a formato colunar, consultas SQL in-process e boa interoperabilidade com Arrow e Parquet. Essa camada concentra o estado do pipeline em tabelas normalizadas de amostras, ASVs, taxonomia e metricas derivadas, reduzindo dependencia de arquivos temporarios CSV e melhorando reproducibilidade.

3.2. Engenharia de Atributos

As transformacoes tabulares foram implementadas com **Polars**, priorizando operacoes vetorizadas e boa escalabilidade em matrizes de alta dimensionalidade. A normalizacao CLR passou a ser a forma padrao de gerar matrizes para aprendizado supervisionado. Tambem foram incorporadas rotinas para filtragem por prevalencia, diversidade alfa (Shannon, Chao1, Simpson) e diversidade beta com distancia Bray-Curtis.

3.3. Modelagem e Avaliacao

No modulo de aprendizado de maquina foram estabilizadas classes para classificacao, regressao e clustering, com uso de `scikit-learn` e `XGBoost`. O desenho experimental

passou a incorporar comparacao entre *baseline* majoritario, Random Forest, SVM e XGBoost, sob diferentes normalizacoes (*raw*, TSS e CLR). Alem de acuracia, o trabalho passou a considerar F1-macro, *balanced accuracy* e ROC-AUC, o que melhora a leitura do desempenho em cenarios com desbalanceamento entre classes.

3.4. Hipotese Experimental

A hipotese central do trabalho foi explicitada da seguinte forma: *a normalizacao composicional CLR melhora a separacao entre classes ambientais e o desempenho preditivo em relacao a abundancias brutas, mantendo coerencia biologica nos atributos mais discriminantes.* Essa formulacao desloca o FLORA de uma prova de conceito apenas tecnica para um estudo comparativo com valor cientifico verificavel.

3.5. Ligacao entre pipeline biologico e modelagem

Para fins de interpretacao metodologica, o pipeline foi compreendido em duas camadas articuladas. A primeira e biologica: controle de qualidade dos reads, remocao de primers, *denoising* por DADA2, geracao de ASVs, remocao de quimeras e classificacao taxonomica. A segunda e computacional: ingestao em DuckDB, transformacao composicional, filtragem por prevalencia, diversidade, treinamento supervisionado e interpretacao das features. O valor cientifico do FLORA depende exatamente dessa continuidade entre preparo biologico e inferencia estatistica.

3.6. Documentacao e Visualizacao

O projeto passou a gerar relatorios HTML autocontidos com visualizacoes interativas. Paralelamente, foram produzidos artefatos estaticos em PNG e documentos em Markdown para uso direto em relatorios institucionais e apresentacoes. Esse passo conecta a camada computacional ao produto academico esperado em PIBIC.

4. Resultados Parciais e Discussao

No periodo avaliado, houve uma redefinicao arquitetural importante. A proposta inicial dava maior peso a uma interface grafica, mas a experiencia de desenvolvimento mostrou que a sustentabilidade do projeto dependia da consolidacao previa de um nucleo cientifico robusto. A partir disso, o FLORA passou a ser organizado como biblioteca modular, sobre a qual interfaces e automacoes podem ser construidas com menor risco tecnico.

Os principais avancos consolidados foram:

- **camada DuckDB estabilizada:** unificacao do pipeline em banco analitico local e persistencia de tabelas biologicas e metricas derivadas;
- **ingestao de dados reais do EMP:** incorporacao de caminho robusto de ingestao por BIOM filtrado por metadados, reduzindo custo computacional e aumentando estabilidade;
- **pipeline composicional:** geracao automatica de matriz CLR com filtragem por prevalencia para alimentar modulos de ML;
- **visualizacao e relatorios:** geracao de relatorio HTML, markdown analitico e figuras estaticas prontas para relatorio academico;
- **suite de testes funcional:** a bateria de testes executou integralmente com 73 testes aprovados sem falhas funcionais.

4.1. Experimento com Earth Microbiome Project

Foi executada uma pipeline completa com dados locais do Earth Microbiome Project. A Tabela 1 resume os principais indicadores obtidos.

Table 1: Resumo quantitativo da pipeline EMP no FLORA.

Indicador	**Valor**
Amostras ingeridas	89
Amostras usadas no modelo	85
Observacoes ASV carregadas	28.857
Taxonomias carregadas	197.711
Features apos filtro de prevalencia	1.183
Acuracia no conjunto de teste	0,8636
F1-macro no conjunto de teste	0,6381
ROC-AUC	0,9510
Shannon medio	3,5223
Chao1 medio	354,84

Os resultados sugerem que a estrutura do dado possui sinal suficiente para discriminacao entre categorias ambientais selecionadas. O ROC-AUC elevado mostra bom poder discriminativo global. Em contrapartida, o F1-macro mais moderado indica que o desbalanceamento entre classes ainda afeta a distribuicao de erros, especialmente nas categorias com menos

amostras. Esse comportamento era esperado e reforca a necessidade de interpretar a qualidade preditiva para alem da acuracia agregada.

4.2. Comparacao metodologica

Um avanco importante do periodo foi a introducao de comparacao entre configuracoes metodologicas distintas. No benchmark atual, `CLR + XGBoost` apresentou o melhor equilibrio entre acuracia, *balanced accuracy* e F1-macro. Em paralelo, `TSS + Random Forest` tambem apresentou desempenho elevado, enquanto o *baseline* majoritario confirmou que a tarefa nao pode ser analisada apenas pela frequencia da classe dominante. Esse resultado constitui evidencia inicial de que a camada composicional agrega valor real ao pipeline.

4.3. Relacao entre ML e biologia

Outro avanco importante foi a reconexao entre atributos discriminantes e grupos taxonomicos plausiveis. Entre os filos mais frequentes nas top features apareceram Proteobacteria, Planctomycetes, Firmicutes e Bacteroidetes. Isso fortalece a interpretacao do modelo, pois o resultado deixa de ser apenas numerico e passa a ser biologicamente discutivel em termos de assinaturas microbianas e contexto ecologico.

4.4. Interpretacao dos Graficos

As figuras geradas cumprem papeis complementares no relatorio:

- **PCoA Bray-Curtis:** mostra estruturacao global e separacao composicional entre grupos ambientais;
- **Shannon e Chao1:** quantificam diversidade local sob perspectivas complementares de uniformidade e riqueza;
- **barplot taxonomico e heatmap taxonomico:** conectam separacao estatistica a assinaturas biologicas observaveis;
- **ROC e matriz de confusao:** permitem auditar desempenho do classificador sob metodos distintos;
- **importancia de features e SHAP:** indicam quais ASVs sustentam as decisoes do modelo.

Esses resultados fortalecem a ideia de que o FLORA ja ultrapassou a fase de prototipagem conceitual e passou a oferecer uma base operacional para estudos aplicados em microbioma.

4.5. Limitacoes

Apesar dos avancos, algumas limitacoes precisam ser reconhecidas explicitamente:

- a secao biologica ainda precisa detalhar com maior rigor primers, regiao-alvo e parametros de *denoising*;
- a validacao principal ainda esta concentrada no EMP, o que exige ampliacao para mais datasets reais;
- a etapa de SHAP ainda depende de estabilizacao do ambiente computacional;
- o benchmark ampliado ainda tem custo computacional relevante, exigindo refinamento operacional e checkpoints.

5. Cronograma e Proximos Passos

Para o proximo periodo, o projeto deve concentrar esforcos em quatro frentes:

- ampliar o repertorio estatistico com metodos de abundancia diferencial;
- refinar a camada de interpretabilidade e resolver incompatibilidades ambientais em dependencias como SHAP;
- consolidar a interface de usuario local e o empacotamento para uso por nao programadores;
- elevar cobertura de testes e validacao cruzada em novos datasets publicos.

5.1. Plano de acao imediato

Semana 1: definir formalmente a hipotese do trabalho e consolidar os experimentos comparando com e sem CLR.

Semana 2: incorporar *baseline* de ML, rodar validacao cruzada repetida e consolidar tabela comparativa central.

Semana 3: escrever a secao de comparacao, melhorar a discussao dos resultados e fortalecer a ligacao entre sinal de ML e plausibilidade biologica.

6. Conclusao Parcial

O desenvolvimento do FLORA no periodo analisado resultou em avancos tecnicos consistentes e alinhados aos objetivos de uma iniciacao cientifica em software cientifico. A mudanca de foco, da interface para a consolidacao da biblioteca, mostrou-se correta do ponto de vista metodologico. O projeto ja oferece ingestao de dados reais, armazenamento analitico robusto, transformacoes composicionais, modelagem supervisionada, visualizacao e relatorios reproduziveis.

Como resultado, o FLORA se posiciona nao apenas como um prototipo de interface, mas como uma infraestrutura computacional em evolucao para analise de microbiomas. O que falta agora nao e mais apenas desenvolvimento tecnico, mas evidencia comparativa suficiente para provar cientificamente o valor do que foi construido. A etapa seguinte consiste em expandir confiabilidade estatistica, cobertura experimental e usabilidade, aproximando o projeto de um produto cientifico publicavel e reutilizavel.

Referencias Bibliograficas

[1] BOLYEN, E. et al. Reproducible, interactive, scalable and extensible microbiome data science using QIIME 2. **Nature Biotechnology**, v. 37, p. 852–857, 2019.

[2] CALLAHAN, B. J. et al. DADA2: High-resolution sample inference from Illumina amplicon data. **Nature Methods**, v. 13, p. 581–583, 2016.

[3] GLOOR, G. B. et al. Microbiome datasets are compositional: and this is not optional. **Frontiers in Microbiology**, v. 8, 2224, 2017.

[4] RAASVELDT, M.; MUEHLEISEN, H. DuckDB: an embeddable analytical database. **Proceedings of SIGMOD 2019**, p. 1981–1984, 2019.

[5] LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. **Advances in Neural Information Processing Systems**, v. 30, 2017.

Joao Pedro Pereira Santiago
Bolsista de Iniciacao Cientifica

Prof. Dr. Diego Lisboa Rios
Orientador do Projeto